PRÉPARATION DE DONNÉES POUR SANTÉ PUBLIQUE FRANCE

(OPEN FOOD FACTS)

Contexte & mission

Accélérer et fiabiliser la saisie Open Food Facts grâce à la suggestion automatique

Irritants actuels

- **Saisie lourde** → erreurs et lenteur
- **Incohérences** (sel/sodium, unités)
- **Manquants** nombreux sur variables clés
- **Doublons** et produits “quasi identiques”

Solution proposée

- **Auto-complétion** des champs clés
- **Règles métier** (ex. 1 g sel = 0,4 g sodium)
- **Pipeline ré-exécutable** et **robuste**
- **Suivi continu de la qualité** : complétude, cohérence, alertes d’anomalies

Ingestion | Nettoyage | Contrôles | Imputation | Analyses | Suggestions

Critères de succès

- **Complétude** ↑ sur les champs clés
- **Erreurs** ↓ (cohérences respectées)
- **Temps de saisie** ↓

Périmètre & contraintes

- **Focus** : nutriments + catégories PNNS.
- **Vie privée** : **pas de données perso** → **RGPD OK**.
- **Attendus** : solution **explicable**, basée sur des **règles**, et **réactive**.

Données & cible

Source (Open Food Facts)

- Jeu **de données public** d'*Open Food Facts*, sous forme de fichier **CSV** ou **JSON**
- Valeurs nutritionnelles exprimées pour 100 g
- Chaque produit étiqueté avec des catégories PNNS (grands groupes « niv 1 » et sous-groupes « niv 2 »
- Champs texte décrivant le produit (nom, description…)
- Traçabilité : métadonnées du dump conservées (date, version, nb lignes…)

Cible retenue : pnns_groups_1

- Grandes familles PNNS (9-10 catégories)
- Choix : lisible pour l'usager, prédictible via nutriments
- Critères de sélection : complétude > 50%, nombre d'individus OK

Features explicatives

- **product_name** ..... Nom du produit (texte)
- **generic_name** ..... Nom générique (texte)
- **energy_100g** ..... Énergie (kJ/100g)
- **fat_100g** ..... Lipides (g/100g)
- **saturated-fat_100g** ..... Acides gras saturés (g/100g)
- **carbohydrates_100g** ..... Glucides (g/100g)
- **sugars_100g** ..... Sucres (g/100g)
- **proteins_100g** ..... Protéines (g/100g)
- **salt_100g** ..... Sel (g/100g)
- **sodium_100g** ..... Sodium (g/100g)
- **nutrition-score-fr_100g** ..... Score nutritionnel (pour 100 g)
- **additives_n** ..... Nombre d'additifs (nb)
- **ingredients_from_palm_oil_n** ..... Ingrédients issus de palme (nb)
- **ingredients_that_may_be_from_palm_oil_n** ..... Ingrédients possiblement palme (nb)

Pipeline de nettoyage (vue d'ensemble)

Filtrage initial

- Retirer les lignes sans cible **pnns_groups_1**.
- **Supprimer les doublons produits** (même code barre / même quantité de macronutriments).

Contrôles métier

- Bornes & unités (kJ/100g)
- Rapports logiques : sel ≈ 0,4 × sodium
- Macro : lipides + glucides + protéines ≤ 100 g

Outliers & Manquants

- Outliers : **IQR** ou **Z-score**, puis **cap** / **suppression**
- Manquants : **KNNImputer** (voisins similaires) **par groupe PNNS**.

Automatisation

- **Scripts modulaires réutilisables** (par étape du processus)
- **Ré-exécutable sans retouche** à chaque mise à jour de la base

Exemples de règles clés

- Sodium ≈ 2,5 × sel (ou sel ≈ 0,4 × sodium)
- Énergie ≤ 4000 kJ / 100 g ; variables en g/100 g entre 0 et 100
- Contrôle additifs/palme : valeurs entières, non négatives

Outliers — Application des règles métier

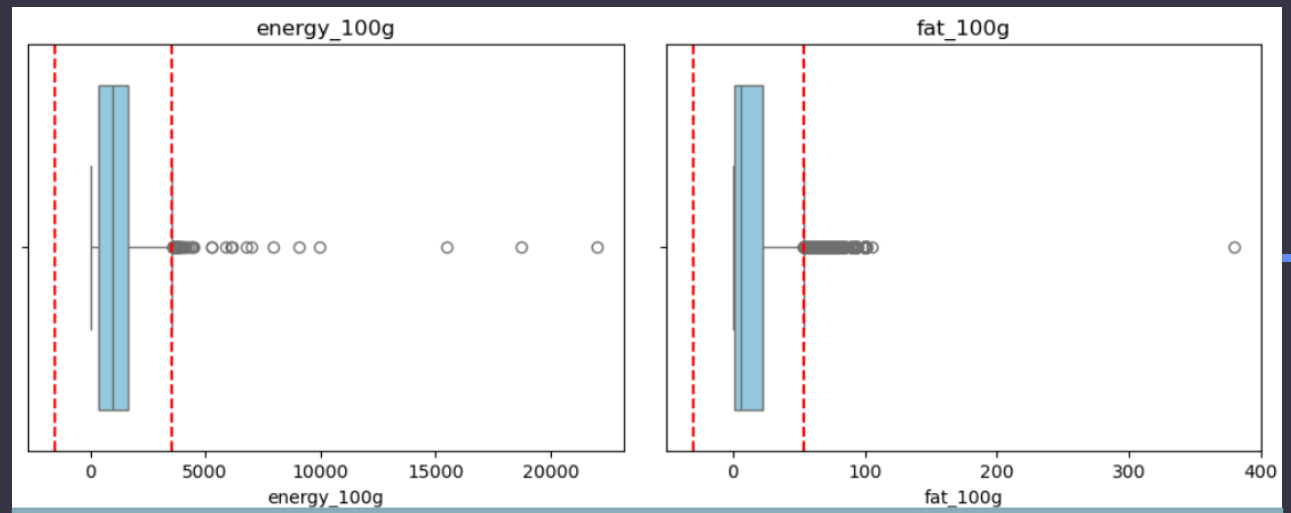

Box Plots de la distribution des individus pour energie_100g et fat_100g

Valeurs > 100g pour 100g :
Physiquement impossible

Énergie maximale théorique :
900kcal/100g
→ Soit 3 766kJ/100g

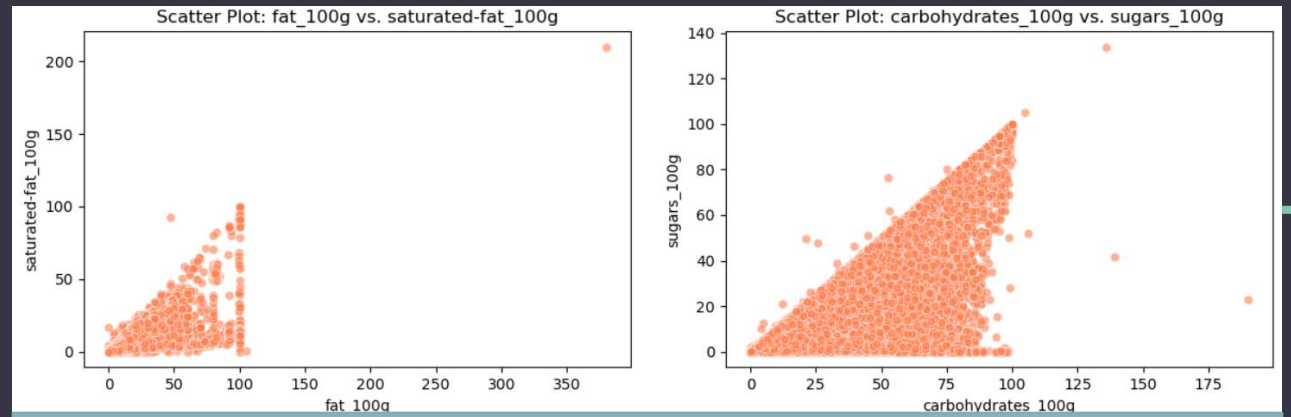

Scatter plots de l'intéraction entre macronutriments et micronutriments

Focus sur le ratio macronutriments vs micornutriments

3 vérifications de rapports logiques

- Graisses saturées ≤ Lipides
- Sucres ≤ lucides
- Sodium = 0.4 * Sel

Valeurs manquantes — Vue globale

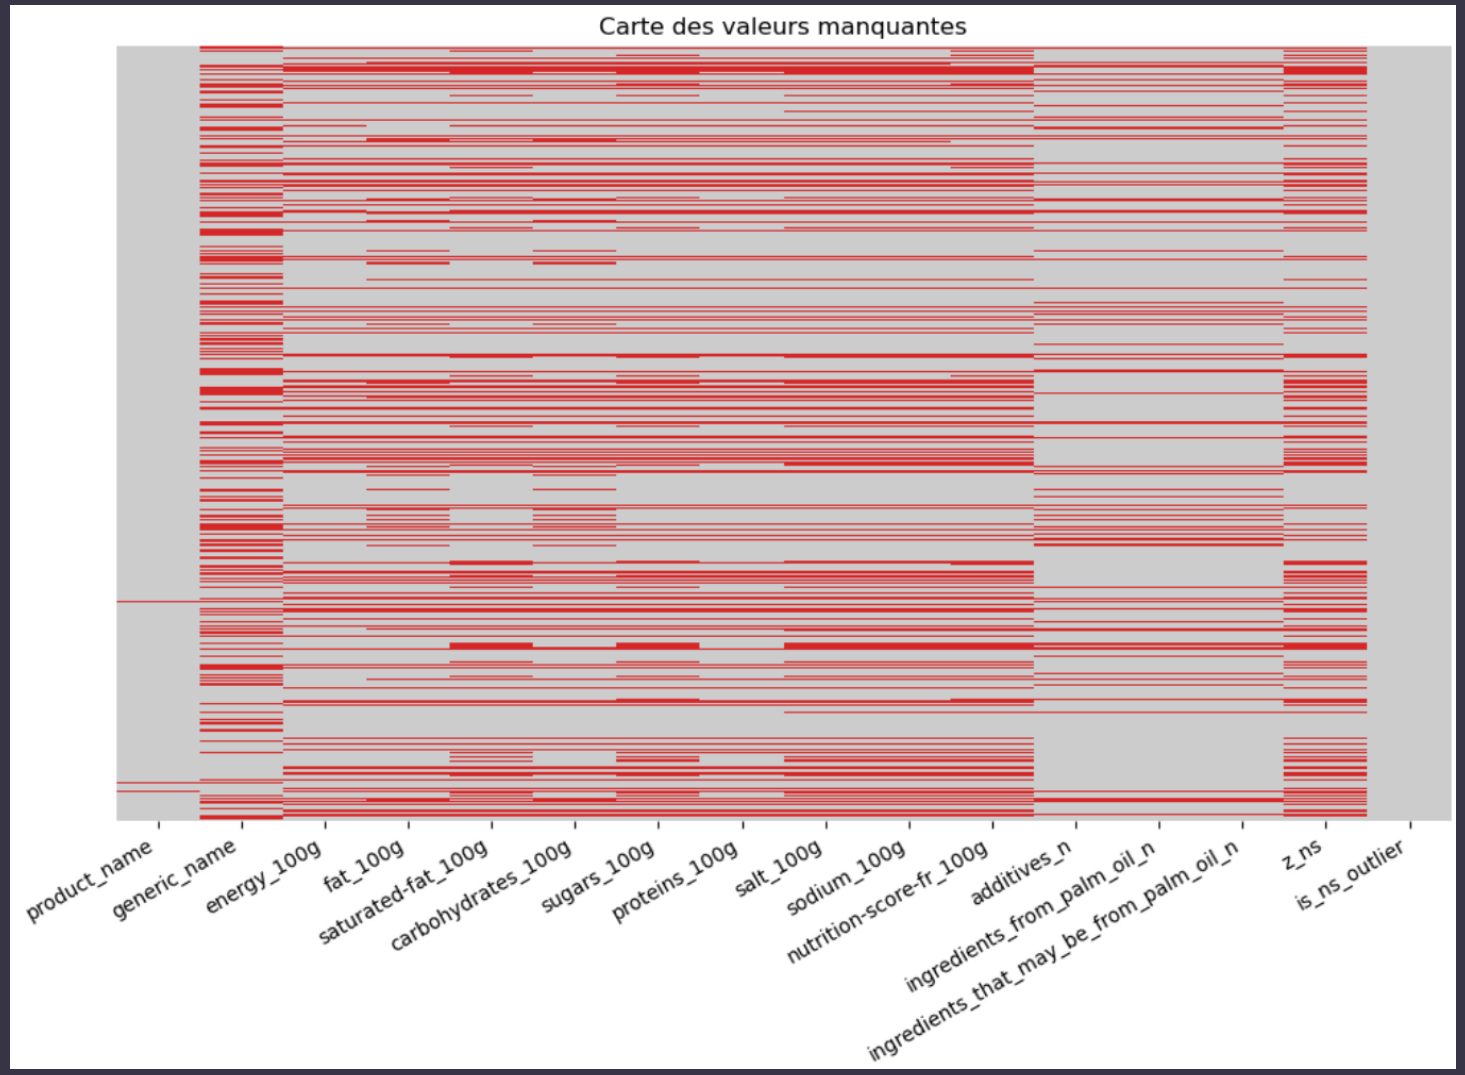

Colonnes les plus touchées → blocs corrélés

- Nutriments manquants **en même temps** (energy, fat, carbs, sugars, proteins, salt, sodium)
- Blocs similaires : **nutrition-score + z_ns**, & **additifs/palme (3 champs)**
- → Missingness **en blocs (MAR)**, pas aléatoire

Décision d'imputation adaptée

- Imputation **par blocs** et **par PNNS** (KNN ou médiane de la catégorie)

Répartition PNNS (après suppression des lignes très incomplètes)

- **Filtre appliqué :** retrait des produits avec **> 6 valeurs manquantes** (qualité minimale garantie).
- **Répartition PNNS restante :** diversité maintenue ; **Sugary snacks ~19 %** (plus gros groupe) ⇢ **Salty snacks ~4–5 %** (plus petit).
- **Équilibre des classes :** déséquilibre **modéré** ; OK pour l'exploration. *À prévoir pour la suite* : échantillonnage stratifié / **class weights** si apprentissage supervisé.

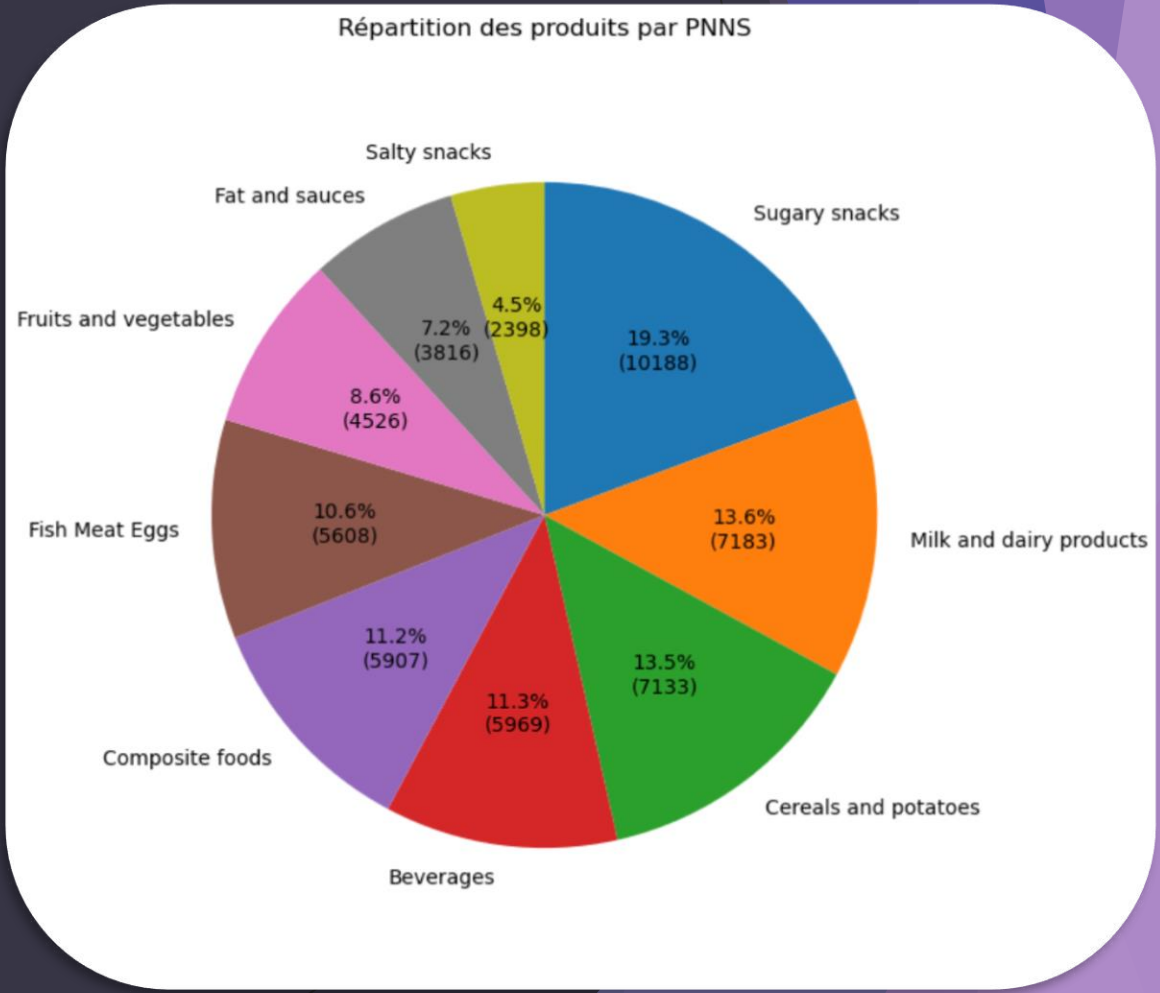

Valeurs manquantes — Co-occurrences

Blocs MAR identifiés

- Additifs & palme
- Sel & sodium
- Lipides & glucides
- Saturés / sucres / sel / sodium / score

Stratégie d'imputation

- **Par blocs & par PNNS : KNN**
- **Cas métier : additifs/palme** → **0** si absence d'info.
- **Fallback** : médiane du **groupe PNNS.**

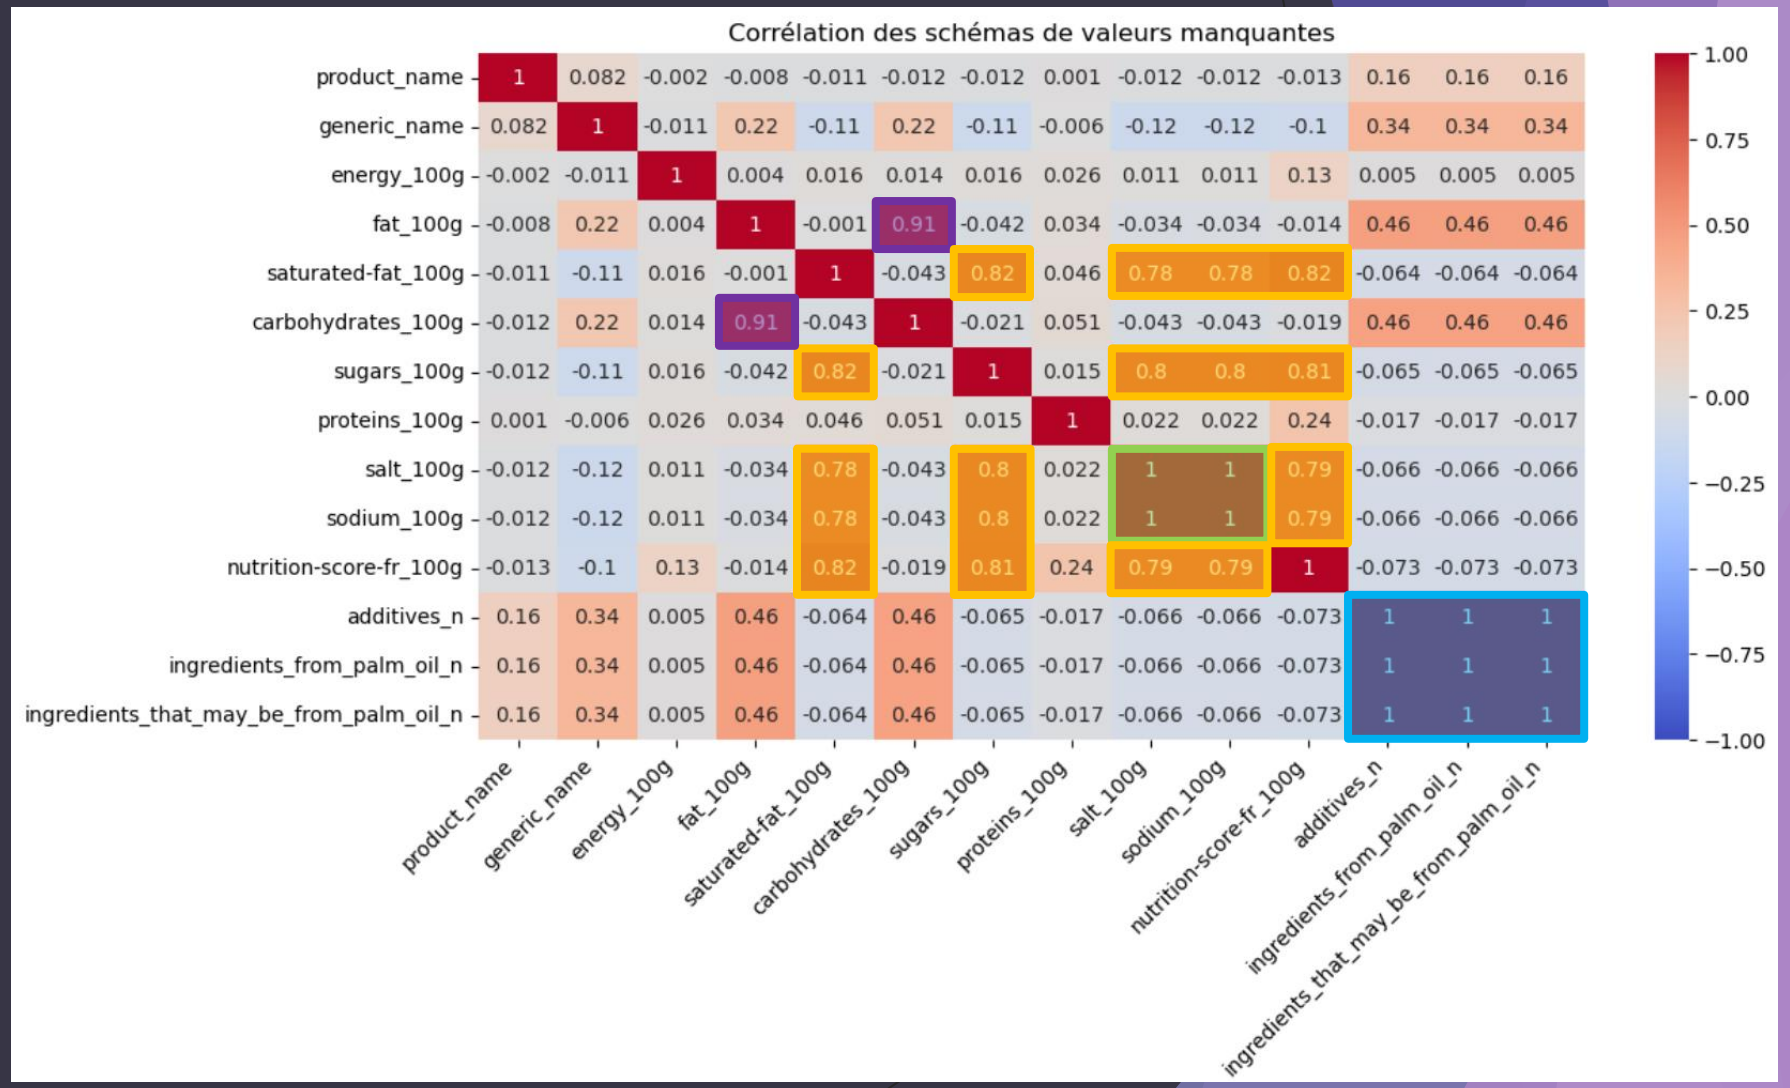

Analyse univariée — Distributions clés

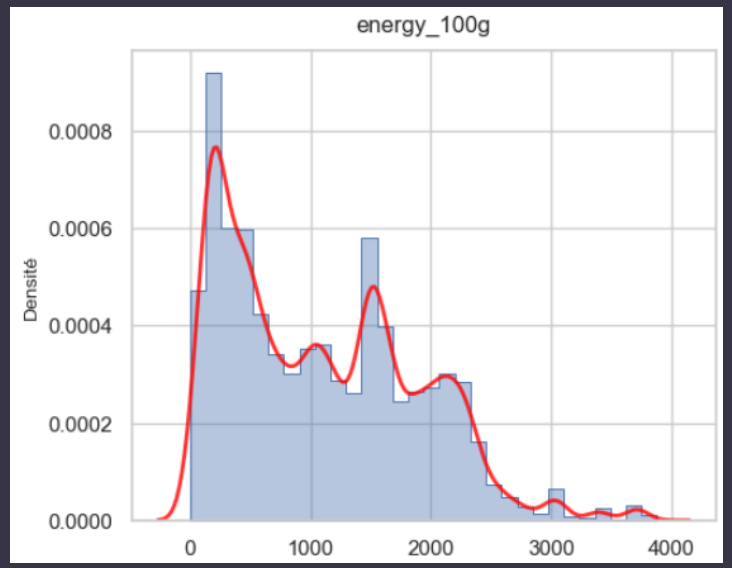

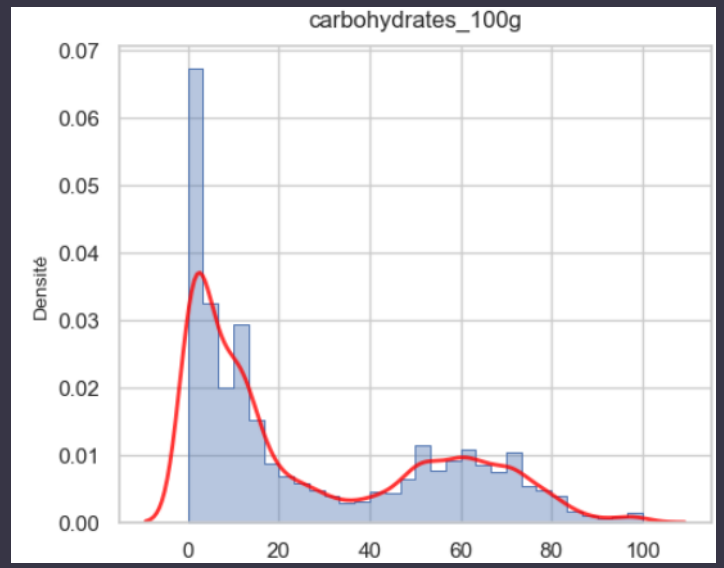

Énergie	Glucides	Score nutritionnel
• **Bimodal** : pic bas (≈ 200–400 kJ) puis pic ≈ 1 000–1 500 kJ. • **Queue droite** jusqu'à ~4 000 kJ ⇒ produits très énergétiques (huiles/graisses). • **Lecture** : coexistence d'aliments « légers » et « denses » en énergie.	• **Deux pics** : ≈ 0–5 g (peu glucidiques) et **40–80 g** (céréales/sucrés). • **Étendue** jusqu'à 100 g. • **Lecture** : sous-populations nettes utiles pour segmenter.	• **Multimodal** : bosses ≈ 0–5 et 10–15, extrêmes possibles. • **Variable ordinale** qui résume le profil nutritionnel. • **Lecture** : diversité des profils A→E ; médiane/IQR plus parlants que la moyenne.

Distributions **asymétriques** et souvent **multi-modales** ⇒ privilégier des métriques **robustes** (médiane/IQR) et des **analyses par segments** pour mieux expliquer/prédire la cible PNNS

Analyse bivariée — Numérique / Numérique

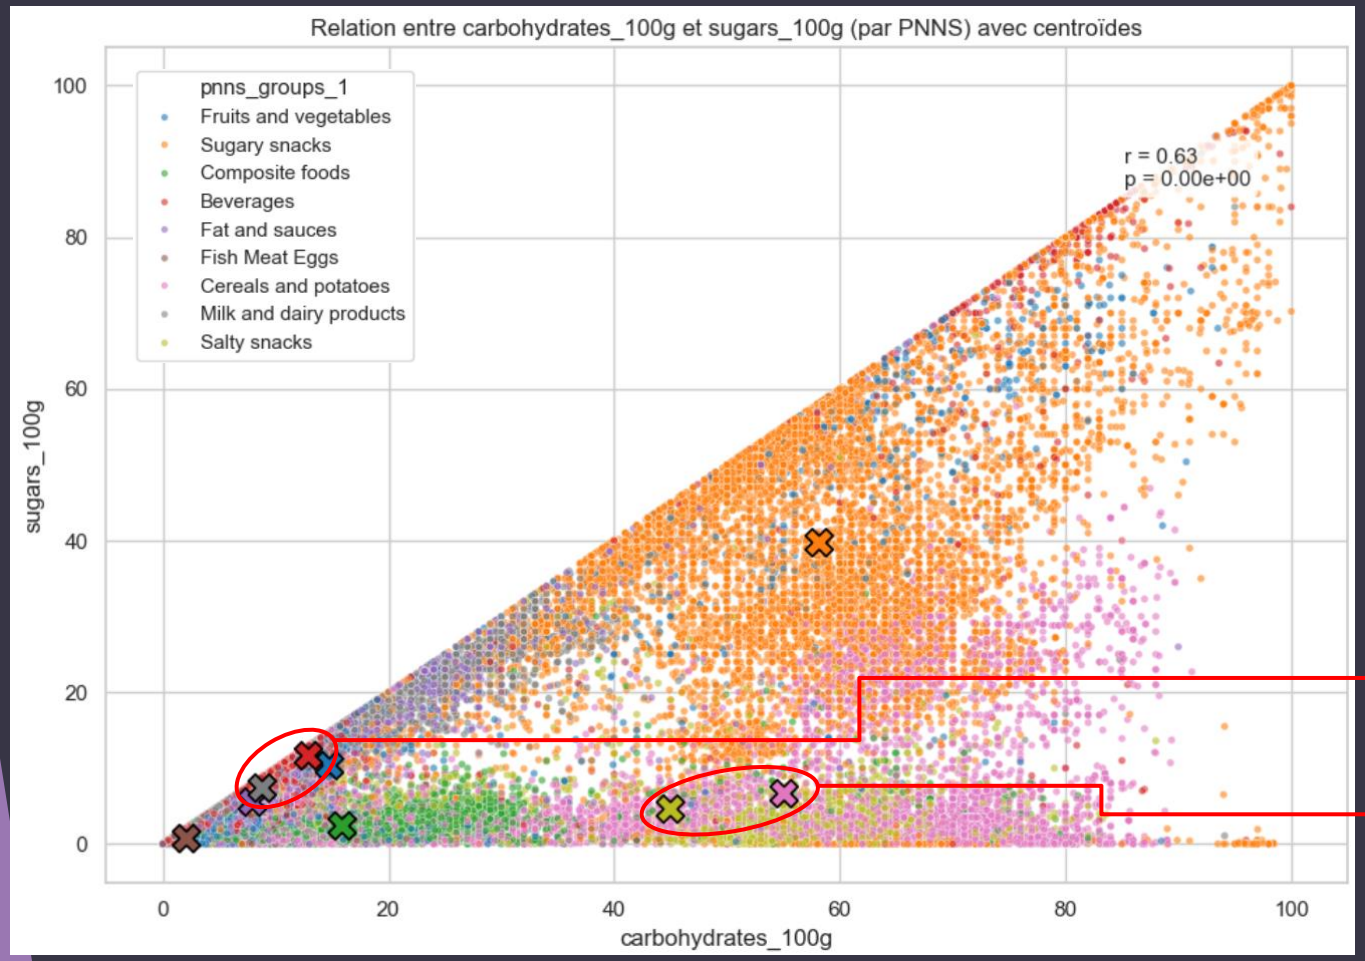

Relation globale

- **r = 0,63 (p≈0)** : lien net *glucides → sucres*.
- Tous les points sous **sucres > glucides** (cohérence).

Quantités (centroïdes)

- **Glucides élevés :** *Sugary snacks* 58g, *Cereals* 55g
- **Faibles** : *Fish/Meat* 2g, *Fat & sauces* 8g
- **Sucres↑**: *Sugary snacks* 40g, *Beverages* 12g

Ratio sucres/glucides

- **Très sucrés :** *Beverages* 0,91; *Milk & dairy* 0,85
- **Amidon/complexes :** *Cereals* 0,12; *Salty snacks* 0,10.

Pour l'app

- Imputation **par PNNS** pertinente.
- Vérification que **sucres ≤ glucides**
- Estimation de *sugars* avec *carbs* + PNNS

Analyse bivariée — Numérique / Catégoriel

Faibles / Modérés en saturés

- **Très faibles** : *Boissons*, *Fruits & légumes* → médiane ≈ **0-0,1 g/100 g**, dispersion minime.

- **Modérés** : *Céréales & pommes de terre* (**Med 0,6 g**), *Plats composés* (**Med 1,8 g**).
→ Profil globalement **peu gras en saturés.**

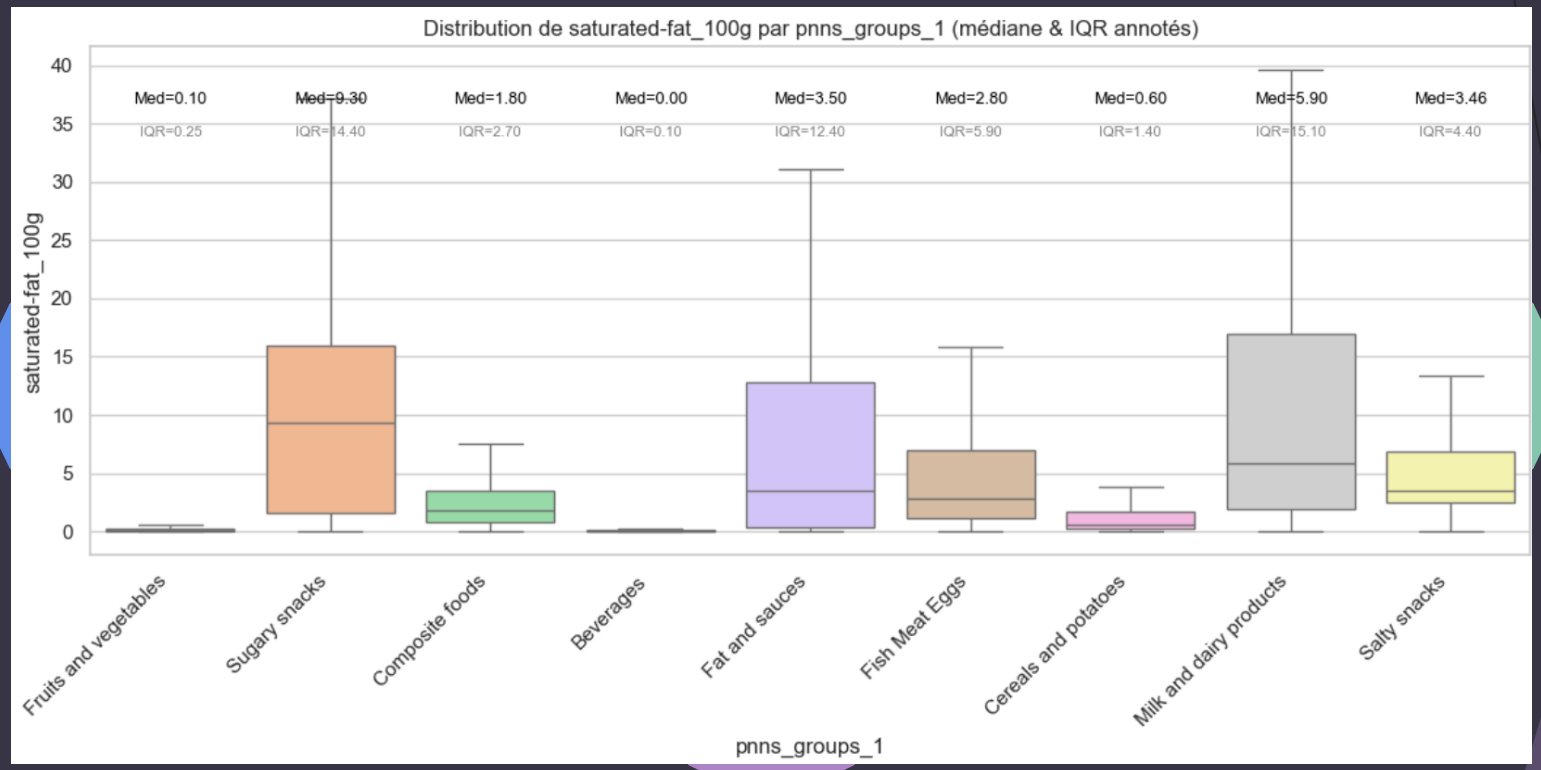

Élevés / Très variables

- **Élevés** : *Snacks sucrés* (**Med 9,3 g**), *Produits laitiers* (**Med 5,9 g**, **IQR 15,1**), *Snacks salés* (**Med 3,46 g**), *Graisses & sauces* (**Med 3,5 g**, **IQR 12,4**).
→ **Beaucoup de saturés** et **forte hétérogénéité** (surtout laitiers & sauces).

Intérêt pour la prédiction PNNS

- Les **médianes/IQR distincts par groupe** offrent des **signaux discriminants.**
- Intégrer *saturated-fat_100g* (avec *fat_100g*) **améliorera la séparation** de classes PNNS, notamment entre *boissons/fruits* (très faibles) et *snacks/laitiers/sauces* (élevés).

Corrélations

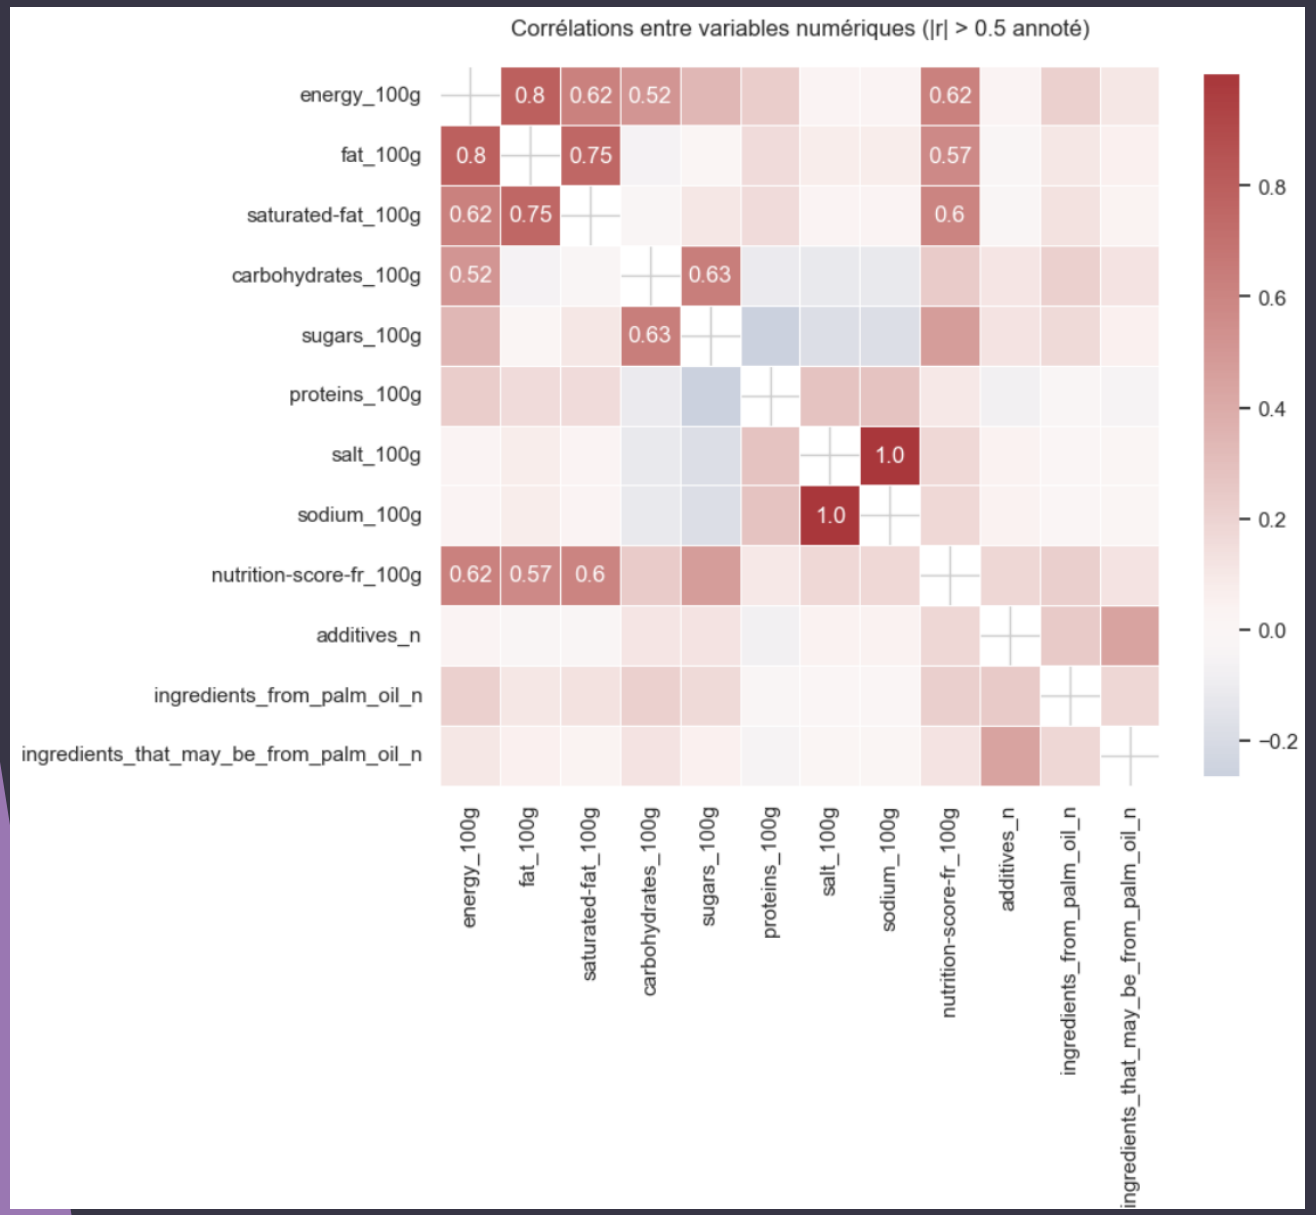

Corrélations fortes (attendues)

- **Sel ↔ Sodium = 1.00** → redondants.
- **Énergie ↔ Lipides = 0.80 ; Saturés ↔ Lipides = 0.75.**
- **Glucides ↔ Sucres = 0.63 ; Énergie ↔ Glucides = 0.52.**

Lien avec le Nutri-Score

- **NS ↔ Énergie = 0.62, NS ↔ Lipides = 0.57, NS ↔ Saturés = 0.60.**

→ Le score est surtout pénalisé par densité énergétique et graisses.

Faibles corrélations

Protéines : pas de r ≥ 0.5 notable.
Additifs / Huile de palme : peu liés aux nutriments → **signal complémentaire pour les prédictions.**

À retenir / décisions

- **Dédupliquer** : garder **sel** *ou* **sodium** (pas les deux).
- Surveiller les **variables très corrélées** (lipides, saturés, énergie) dans les modèles.
- Conserver **additifs/palme** pour un **signal indépendant.**

ACP — Éboulis des valeurs propres

Lecture rapide

- PC1-PC3 (~62 %) : PC1-PC2 / PC1-PC3 suffisent pour voir les écarts PNNS
- PC1-PC4 = ≈**72%** / PC1-PC5 = ≈**81%**
- **Coude** vers **PC4-PC5** : gains ensuite **marginaux**

Règles usuelles

- **≥80% de variance → k = 5**
- **Kaiser (λ ≥ moyenne ≈ 10%) → k = 4**
- Les deux choix sont **cohérents** selon l'objectif

Décision pour ce projet

- Pour **visualiser/interpréter** : **PC1-PC3** (≈**61.9%** cumulée).
- Pour une **réduction plus fidèle** : garder **4-5 PC** si nécessaire plus tard.

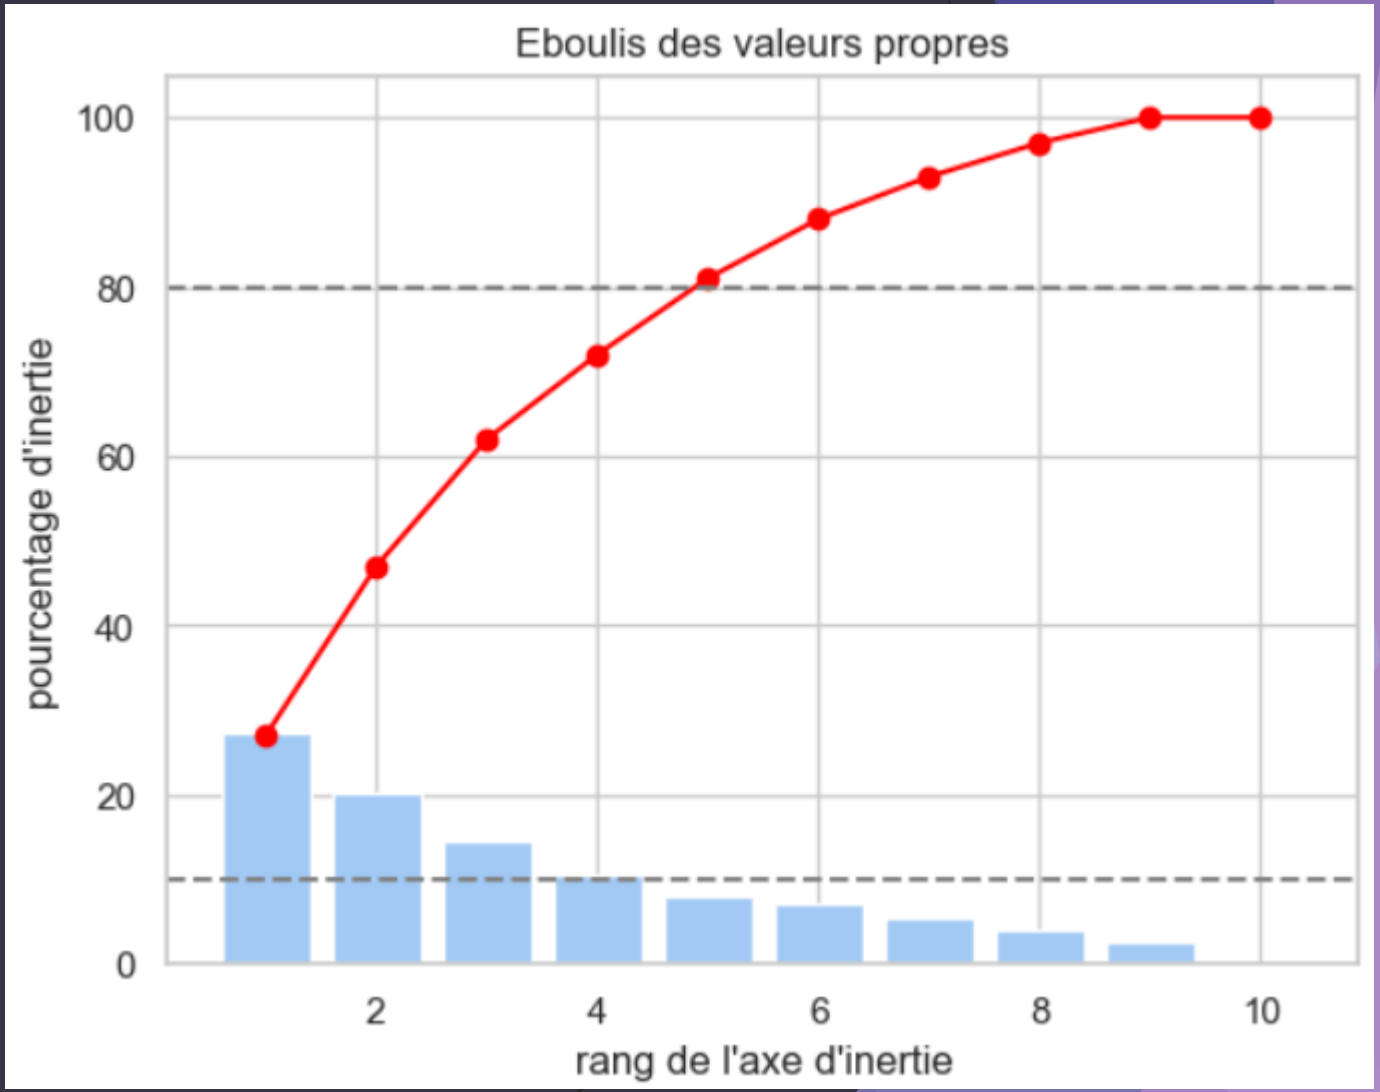

ACP — Cercles de corrélation

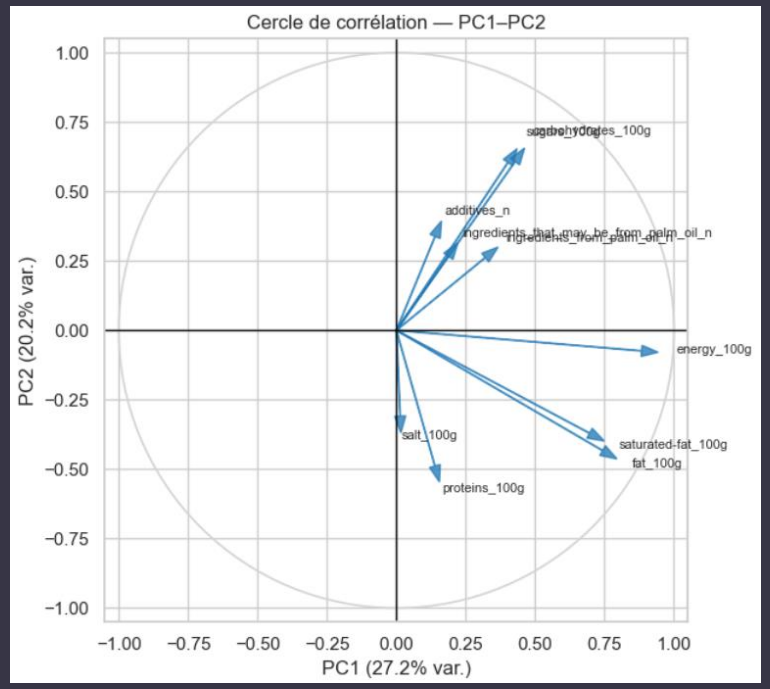

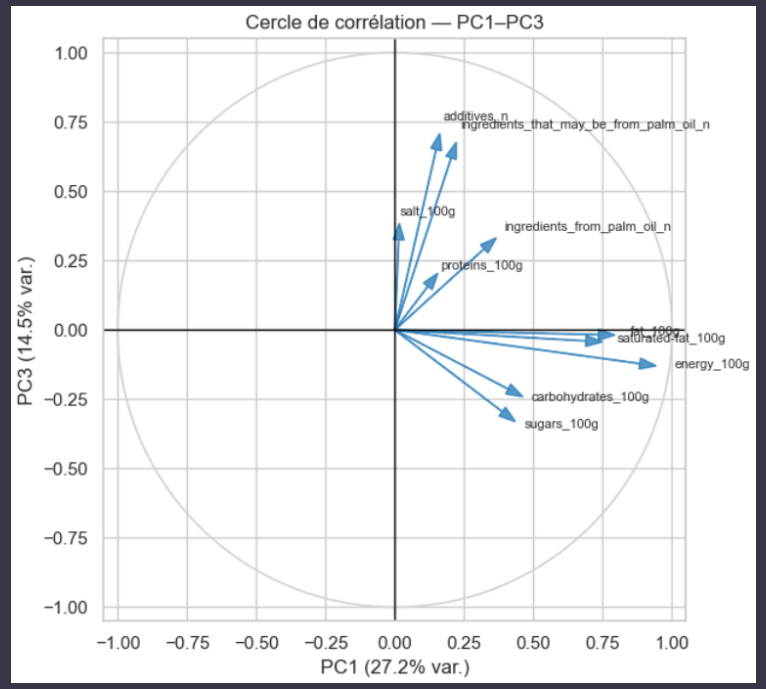

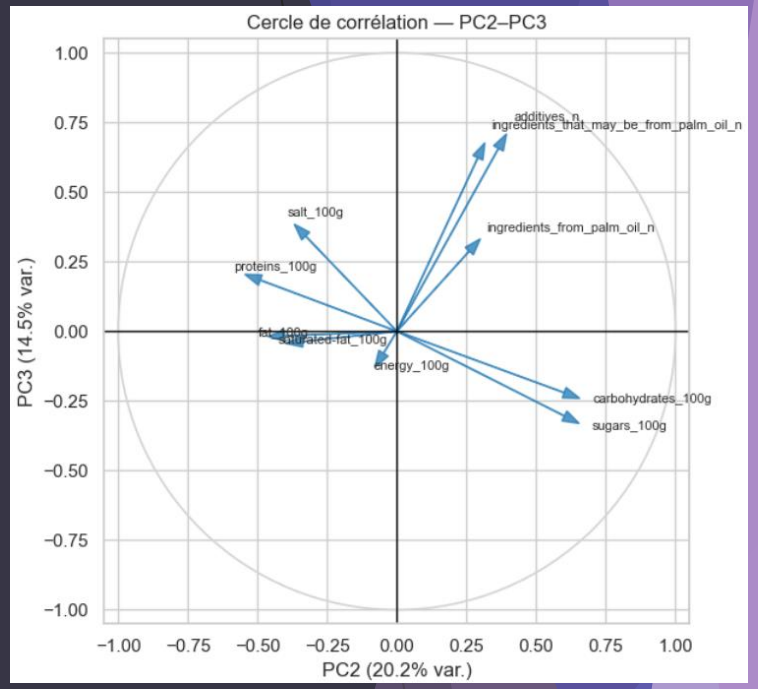

PC1-PC2

- PC1 = **énergie & lipides** (energy, fat, sat-fat) → droite = produits denses/gras
- PC2 = **sucré/glucidique vs salé/protéiné** → haut = (carbs, sugars) ; bas = (proteins, sel)
- **Lecture** : lipides ↔ énergie ; sucres ↔ glucides ; protéines opposées aux sucres

PC1-PC3

- PC1 = **énergie & lipides** (inchangé).
- PC3 = **transformation** → (additifs, palme, un peu sel) en haut
- **Lecture** : dimension "additifs/palme" **orthogonale** au simple niveau d'énergie

PC2-PC3

- PC2 = **sucré (→) vs salé/protéiné (←)**.
- PC3 = **transformation (↑)** → additifs/palme/sel montent.
- **Lecture** : sucré peu transformé (↓/→) vs sucré très transformé (↑/→) ; salé/protéiné souvent plus transformé (↑/←).

Conclusion :

- **PC1** porte le **gras/énergie** ; **PC2** sépare **sucré** vs **salé/protéiné** ; **PC3** ajoute le **niveau de transformation.**
- Les trois plans se complètent pour **lire les profils PNNS** et guider la **prédiction de catégorie.**

ACP — Centroïdes PNNS (PC1–PC2)

Repères des axes

PC1 + → denses/gras · PC1 − → peu énergétiques/peu gras
PC2 + → sucré/glucidique · PC2 − → salé/protéiné

Lecture par quadrants

- **Droite / Haut (PC1+, PC2+)** : Sugary snacks (très énergétiques & sucrés).
- **Droite / Bas (PC1+, PC2−)** : Salty snacks, Fat & sauces (denses & salés).
- **Gauche / Bas (PC1−, PC2−)** : Fish Meat Eggs, Milk & dairy (peu denses, plutôt salés/protéinés).
- **Gauche / Haut (PC1−, PC2+)** : Beverages, Fruits & vegetables (faible densité, léger profil sucré).

Messages clés

- **Bien séparés :** Sugary snacks, Salty snacks, Fat & sauces, Fish Meat Eggs.
- **Centrés / mixtes :** Composite foods, Cereals & potatoes (profils moyens, chevauchements).
- **Axes validés :** PC1 = densité/gras · PC2 = sucré vs salé/protéiné → utiles pour prédire & expliquer.

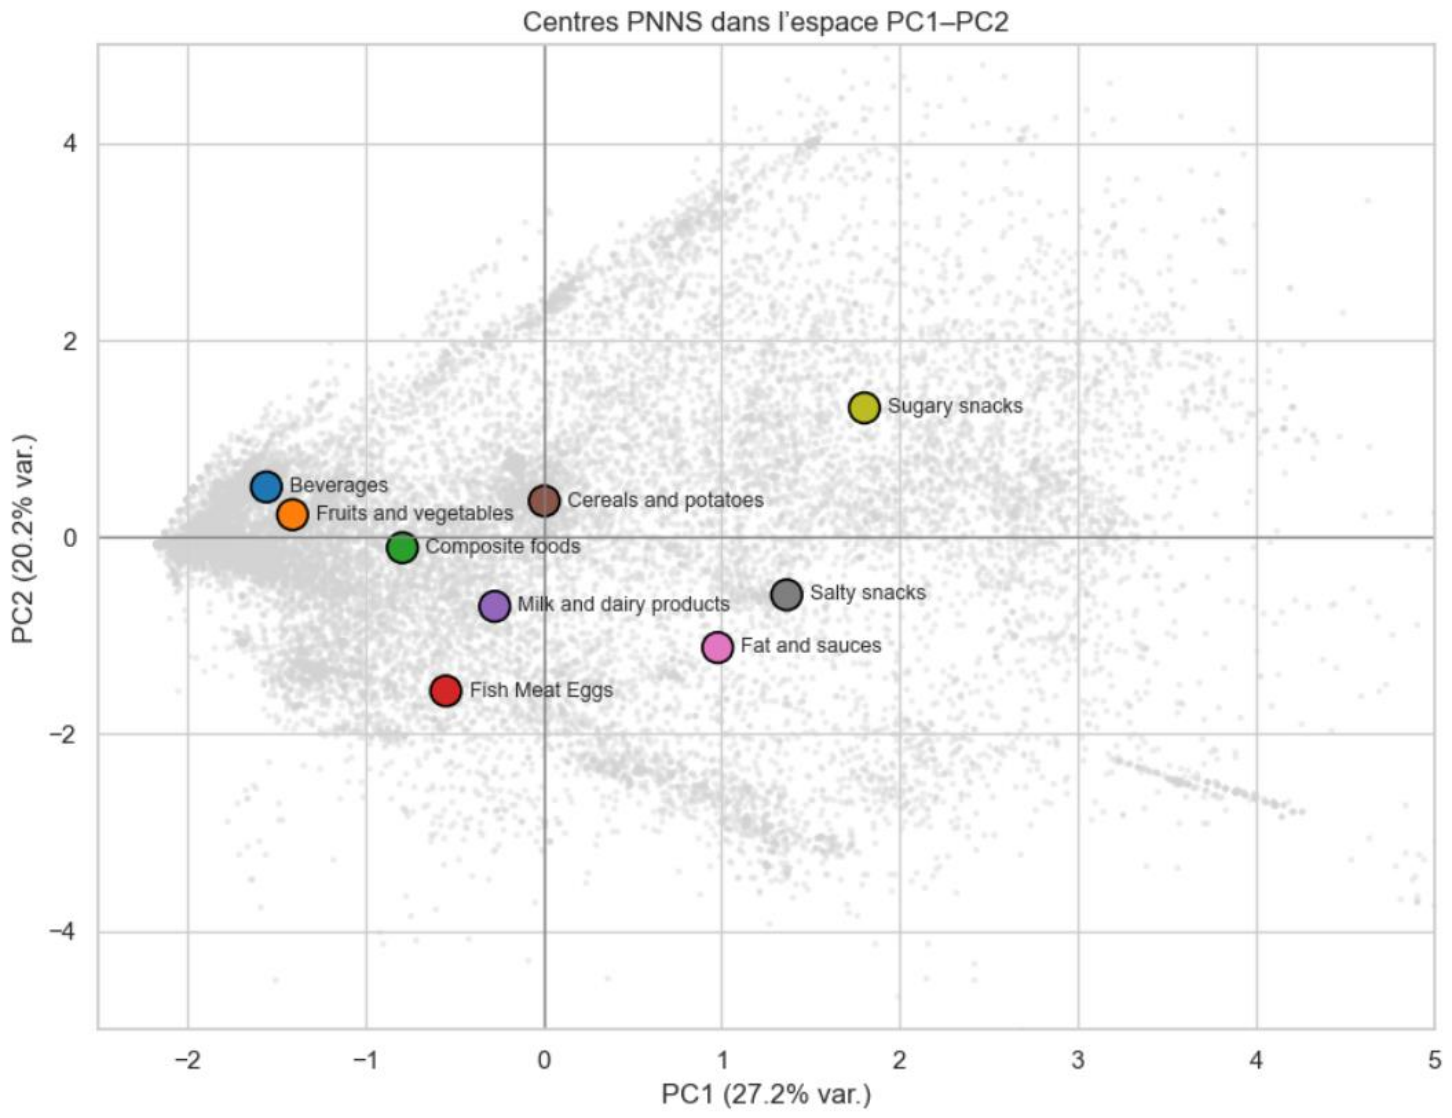

Observations & faisabilité

Ce que montre l'ACP

- **PC1** : niveau d'énergie et de graisses.
- **PC2** : **sucré/glucidique** vs **salé/protéiné**.
- **PC3** : **degré de transformation** (additifs, palme, sel).
- Les **centroïdes PNNS** sont bien séparés : certaines familles ont des profils clairs (snacks sucrés, snacks salés, poissons/viandes/œufs).
- Les **cercles de corrélation** confirment des blocs logiques (énergie–lipides, sucres–glucides) et des oppositions utiles à la prédiction.

Impact pour l'auto-complétion et faisabilité

•Avec **quelques champs** (énergie, lipides, sucres), on **situe** déjà le produit et on peut **suggérer** les valeurs manquantes.
•Les **règles métier** (ex. sel ≈ 0,4 × sodium) sécurisent les propositions quand plusieurs champs manquent.
•**Faisable** : imputation **KNN** ou **médiane par groupe**, complétée par une **PCA** pour la cohérence globale.
•**Vigilance** : certaines catégories **hétérogènes** → afficher une **incertitude** ; pipeline **robuste** aux nouveaux produits.

RGPD — Principes clés & conformité du projet

Finalité & transparence

- Traiter les données pour une **finalité déterminée, explicite, légitime**
  → **Projet** : améliorer **complétude** / **qualité** de saisie
- **Informer** sur qui collecte, pourquoi, comment
  → **Projet** : données **OFF publiques**, doc. claire du pipeline
- **Pas de réutilisation** incompatible avec le projet
  → **Projet** : **pas d'usage marketing** / profilage utilisateur

Minimisation des données

- Collecter **uniquement le nécessaire**
  → **Projet** : uniquement des données de **produits,** pas de donnée à caractère personnel (DCP)
- **Données exactes** et **mises à jour**
  → **Projet** : contrôles métier (sel↔sodium), règles de cohérence
- **Conservation limitée** au besoin
  → **Projet** : versionnage daté des jeux et traitements.

Sécurité & droits

- **Intégrité, confidentialité, disponibilité**
  → **Projet** : pipeline **reproductible**, tests d'anomalies auto
- **Traçabilité** des traitements / incidents
  → **Projet** : versions & journal des transformations (avec suivi des incidents)
- **Accountability** (preuve de conformité)
  → **Projet** : documentation des règles d'imputation

Conformité du projet (RGPD)

- **Pas de données personnelles** : uniquement des informations produit (nutriments, tags).
- **Finalité claire** : aider à **remplir** les fiches plus vite et **mieux**.
- **Principe de minimisation** : on n'utilise **que** les champs nécessaires.
- **Sécurité & traçabilité** : pipeline **documenté**, **reproductible**, contrôles **automatiques** (cohérences, anomalies).

Conclusion & prochaines étapes

Conclusion

- Des **schémas stables et interprétables** relient nutriments et familles **PNNS**.
- Base solide pour un **module de suggestion / auto-complétion** **simple, explicable et fiable** dans Open Food Facts.
- Mise en œuvre facilitée par un **pipeline automatisé** (contrôles métier, imputation par groupes, PCA) **robuste aux nouveaux produits**.

Prochaines étapes

- **Industrialiser** le pipeline avec monitoring qualité.
- **Prototyper** le module de suggestion : quelques champs en entrée → **valeurs proposées + incertitude**.
- **Tester** **avec des usagers** : pertinence des suggestions & **gain de temps** en saisie.

Gardes fous et conformité

- **Bornes & règles métier** : bloquer toute suggestion incohérente (ex. sel ↔ sodium, macros ≤ 100 g).
- **Suivi qualité** : contrôles automatiques + **détection de dérive** sur les nouvelles données.
- **Transparence RGPD** : **aucune donnée personnelle**, règles et choix d'imputation **documentés**.