Projet Seattle

Prédiction de la consommation énergétique et des émissions de CO_2 des bâtiments non résidentiels

Présenté par : Florent GERVAIN-SALGÉ

Formation : Data Scientist - Openclassrooms

Introduction du projet

Contexte

- Ville de Seattle : objectif **neutralité carbone d'ici 2050**
- Les **bâtiments non résidentiels** sont un levier majeur
- Les mesures réelles sont :
  - coûteuses
  - longues à obtenir

→ Besoin d'un **modèle prédictif**

Objectifs

Prédire :

- la **consommation énergétique totale**
- les **émissions de CO_2**

À partir de :

- caractéristiques structurelles
- usage
- localisation

Et évaluer l'intérêt de l' **EnergyStarScore**

Partie 1 : Comprendre les données et leurs relations

Présentation des données

Dataset

Environ **1700 bâtiments non résidentiels**

Variables disponibles :

- caractéristiques structurelles (surface, année de construction, nombre d'étages)
- usage du bâtiment (bureau, laboratoire, entrepôt, etc.)
- localisation (coordonnées, quartier)
- données énergétiques (électricité, gaz, etc.)

Variables cibles

Deux cibles à prédire :

- consommation énergétique totale
- émissions de CO_2

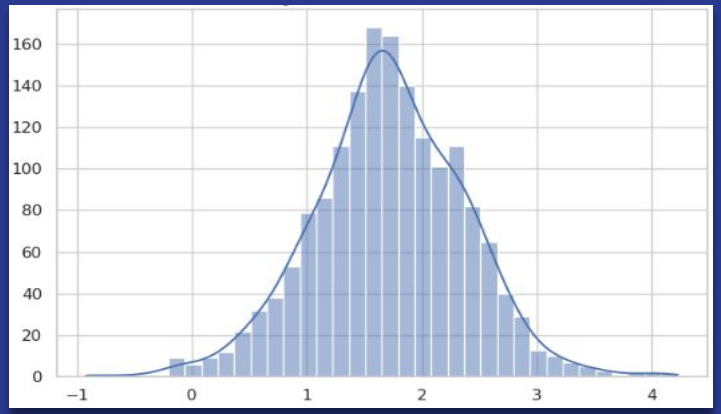

Distribution de la consommation énergétique (log)

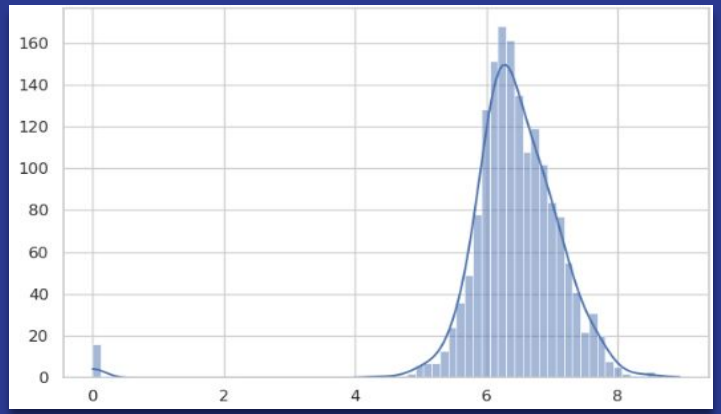

Distribution des émissions de CO_2 (log)

Nettoyage et préparation des données

Filtrage et cohérence

Sélection des **bâtiments non résidentiels**

Suppression des observations incohérentes

- surfaces nulles ou aberrantes
- valeurs énergétiques non exploitables

Vérification de la cohérence des variables structurelles

Gestion des valeurs manquantes

- Analyse du taux de valeurs manquantes
- Suppression des variables trop incomplètes
- Traitement des manquants logiques
- Mise à l'écart de l'ENERGYSTARScore pour analyse ultérieure

Stabilisation statistique

- Distribution fortement asymétrique des cibles
- Application d'une transformation **log1p**
- Réduction de l'impact des valeurs extrêmes

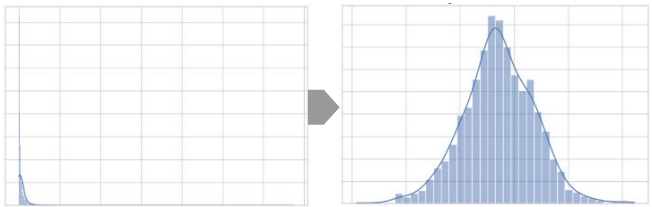

Histogramme avant / après log-transformation

Feature engineering

01

Variables structurelles

→ Permettent de capturer la taille et la structure

- Surface totale
- Surface par usage
- Nombre d'étages
- Année de construction

02

Variables d'usage

→ Transformation via OneHotEncoding

- Bureau
- Laboratoire
- Entrepôt
- Commerce

03

Variables dérivées

→ meilleure capture des profils énergétiques

- Âge du bâtiment
- Ratios de surfaces
- Répartition des usages

Analyse exploratoire - Corrélations entre variables

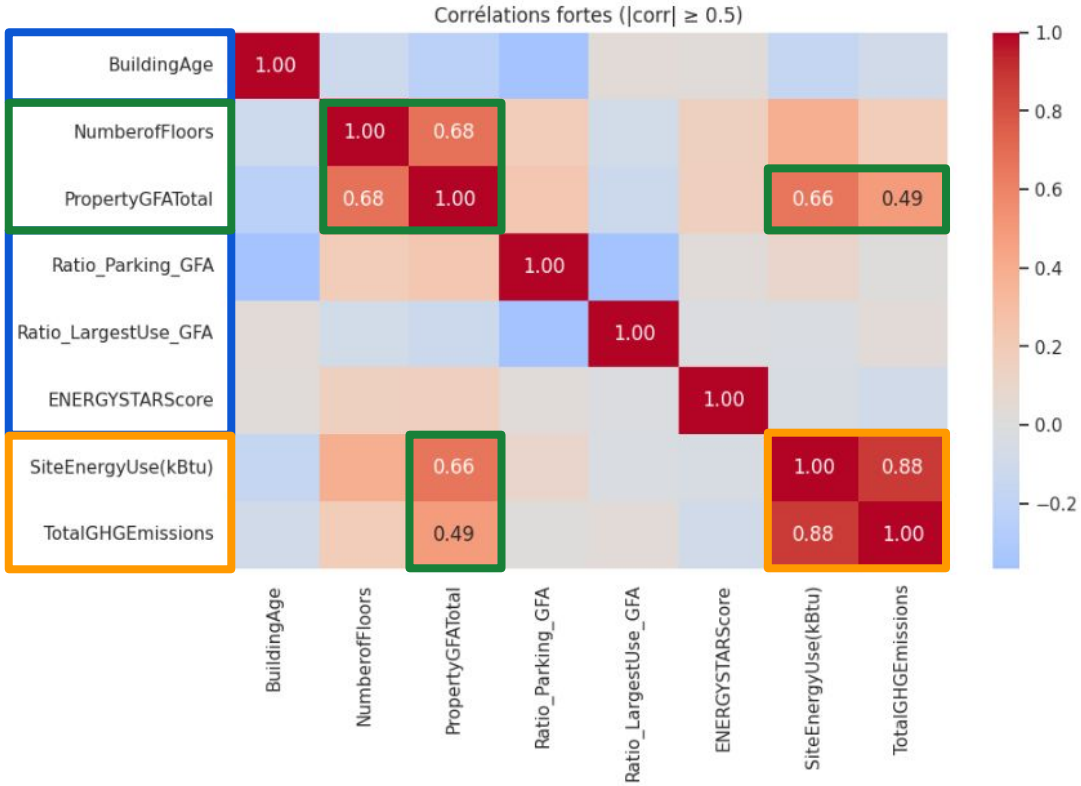

Observations clés

Cibles fortement corrélées
Energy ↔ CO_2 : **0.88**

Surface = facteur dominant
PropertyGFATotal
Energy : **0.66**
CO_2 : **0.49**
Étages : **0.66**

Variables complémentaires
BuildingAge
Ratios de surface
ENERGYSTARScore

Premier modèle benchmark

Comparaison des modèles linéaires

Modèle	R^2 test	MAE test	RMSE test
Dummy (moyenne)	-0.01	8.49M	18.93M
Lasso	0.45	4.94M	12.08M
Ridge	**0.45**	**4.93M**	**12.08M**

Observations

- Les modèles linéaires réduisent fortement l'erreur par rapport au Dummy
- Ridge et Lasso ont des performances très proches
- Les performances restent limités en validation

Modèle benchmark retenu

Ridge Regression

✔ Performances légèrement supérieures

✔ Modèle stable et robuste

✔ Baseline pour la suite du projet

Tests de Feature Engineering

Hypothèses testées

- Transformation **log des surfaces**
- **Réduction du jeu de variables**
- **PCA** pour compresser l'information

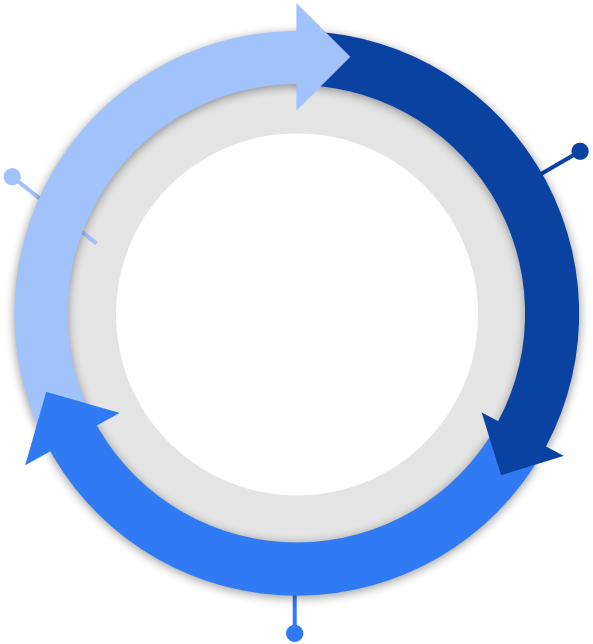

Résultats

- **Baisse du R^2**
- **Augmentation des erreurs** (MAE/RMSE)
- Information **peu compressible**

Décision

Objectif : Laisser les modèles non linéaires exploiter la complexité

✔ **Conserver les features complètes**

→ données nettoyées
→ encodages
→ ratios existants

Transition vers la phase prédictive

Limites du modèle linéaire

- **R^2 limité (~0.45)**
- relations **non linéaires**
- interactions **complexes entre variables**

➡ Capacité explicative encore insuffisante

Modèles plus expressifs

Test de plusieurs familles d'algorithmes :

- **SVM**
- **Random Forest**
- **Gradient Boosting**

Objectif : capturer les **relations non linéaires** et **améliorer les performances**

Partie 2 : Modélisation de la consommation énergétique

Objectif de la modélisation

Prédire la consommation énergétique totale des bâtiments non résidentiels

Benchmark linéaire : **Ridge**

Optimisation du modèle final

Étape 1 → Étape 2 → Étape 3 → Étape 4

Modèles non linéaires :

- SVR
- Random Forest
- Gradient Boosting

Analyse explicative

- XAI
- SHAP

Performances des modèles testés

Modèle	R^2 test	MAE test	RMSE test
Gradient Boosting	**0.72**	**0.51**	**0.69**
Random Forest	0.68	0.55	0.73
SVR	0.62	0.59	0.80
Ridge (benchmark)	0.57	0.64	0.85

Observations

- **Ridge :** baseline solide
- **SVR :** légère amélioration
- **Random Forest :** gain significatif
- **Gradient Boosting : meilleures performances**

Modèle retenu

Gradient Boosting

✔ Meilleur R^2 en validation croisée
✔ Erreurs MAE et RMSE les plus faibles
✔ Capte efficacement les non-linéarités et interactions

Optimisation du modèle final

Objectif : Optimiser le modèle **Gradient Boosting** sélectionné

Hyperparamètres optimisés

- **n_estimators** → nombre d'arbres
- **learning_rate** → vitesse d'apprentissage
- **max_depth** → complexité des arbres
- **min_samples_leaf** → régularisation
- **subsample** → réduction du surapprentissage

Optimisation réalisée avec **RandomizedSearchCV + validation croisée**.

Meilleur modèle obtenu

Gradient Boosting optimisé :

- **R^2 CV ≈ 0.73**
- **RMSE CV ≈ 0.68**
- **MAE en baisse**

✔ Meilleure capacité explicative

✔ Bon compromis biais / variance

✔ Modèle retenu pour la suite

Variables les plus importantes

Surface du bâtiment (facteur dominant)

- **PropertyGFATotal**
- **PropertyGFABuilding(s)**
- **LargestPropertyUseTypeGFA**

Structure des usages

- répartition des surfaces
- usages spécifiques (ex : warehouse, supermarket…)

Variables secondaires

- localisation
- âge du bâtiment
- ratios de surface

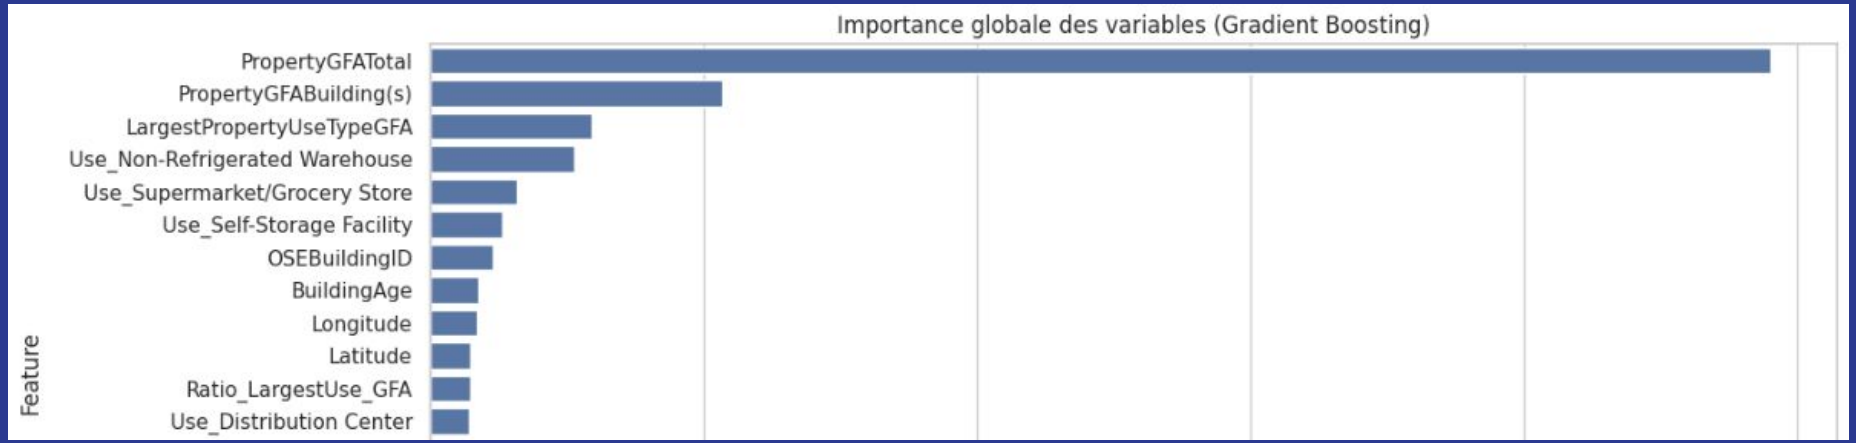

Interprétation locale des prédictions (SHAP)

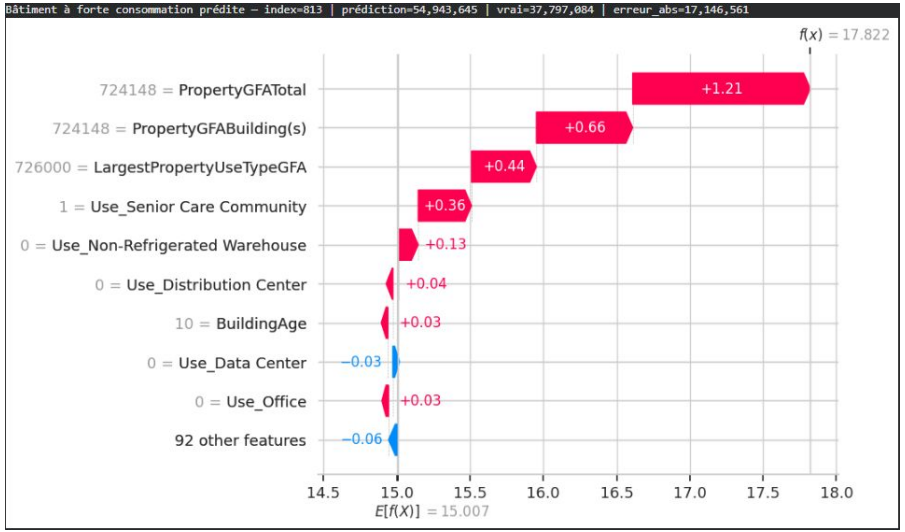

Bâtiment à forte consommation prédite

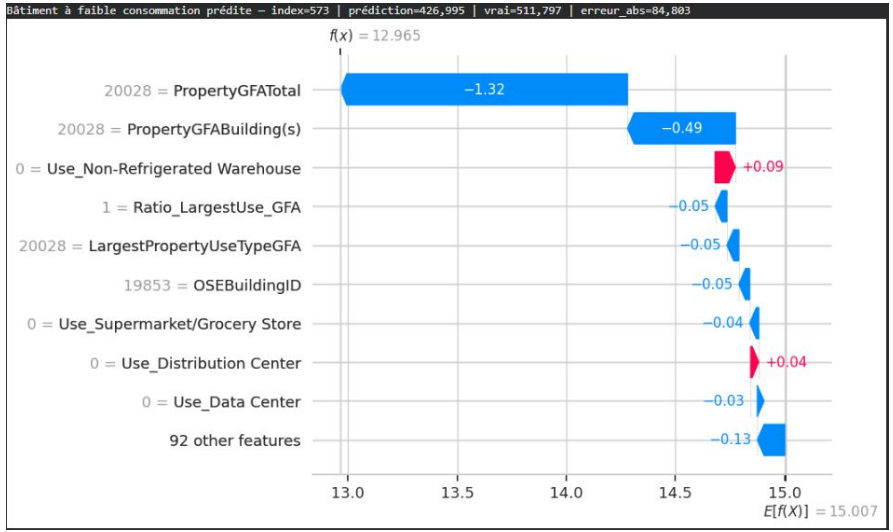

Bâtiment à faible consommation prédite

Bâtiment énergivore

- Surfaces très élevées
- Usage intensif
- Contributions SHAP positives

Bâtiment sobre

- Surface faible
- Usages peu énergivores
- Contribution SHAP négatives

Influence de l'ENERGYSTARScore

Modèle	R^2 CV	MAE CV	RMSE CV
Sans EnergystarScore	0.77	0.45	0.60
Avec EnergyStarScore	0.87	0.32	0.45

Observations

✔ Amélioration des performances
✔ Variable fortement informative
✔ Meilleure précision globale

Point de vigilance

⚠️ Possible **data leakage**
⚠️ Score dérivé de la performance énergétique

Point clé

→ ENERGYSTARScore améliore les prédictions mais peut réduire l'intérêt prédictif du modèle selon le contexte métier

Partie 3 : Prédiction des émissions de CO_2

Objectif : prédiction des émissions de CO_2

1

Objectif

Prédire les **émissions annuelles de CO_2** des bâtiments non résidentiels

2

Cible : TotalGHGEmissions

Indicateur clé pour :

- suivi des émissions des bâtiments
- réduction de l'empreinte carbone urbaine

3

Approche

Même méthodologie que précédemment :

- benchmark linéaire
- modèles non linéaires
- optimisation du meilleur modèle
- interprétation avec SHAP

Comparaison des modèles

Modèle	Type	R^2 CV
Ridge (benchmark)	Modèle linéaire	Baseline
SVR	Modèle à noyau	Amélioration
Random Forest	Modèle ensembliste	Forte amélioration
Gradient Boosting	Modèle séquentiel	**Meilleur modèle**

Observations

- Les modèles non linéaires sont plus performants
- Les modèles d'ensemble capturent mieux les relations complexes

Modèle retenu

Gradient Boosting

✔ Meilleures performances globales
✔ Bon compromis précision / robustesse

Optimisation du modèle final

Résultats avant optimisation

- R^2 : 0.52
- MAE : 0.79
- RMSE : 1.00

Résultats après optimisation

- R^2 : 0.52
- MAE : 0.78 (- 0.01)
- RMSE : 0.99 (- 0.01)

Lecture des résultats

- Amélioration légère mais cohérente
- Erreurs légèrement réduites
- Modèle final conservé pour la suite

Point clé

L'optimisation affine le modèle, sans modifier fortement son niveau de performance

Explication du modèle (SHAP)

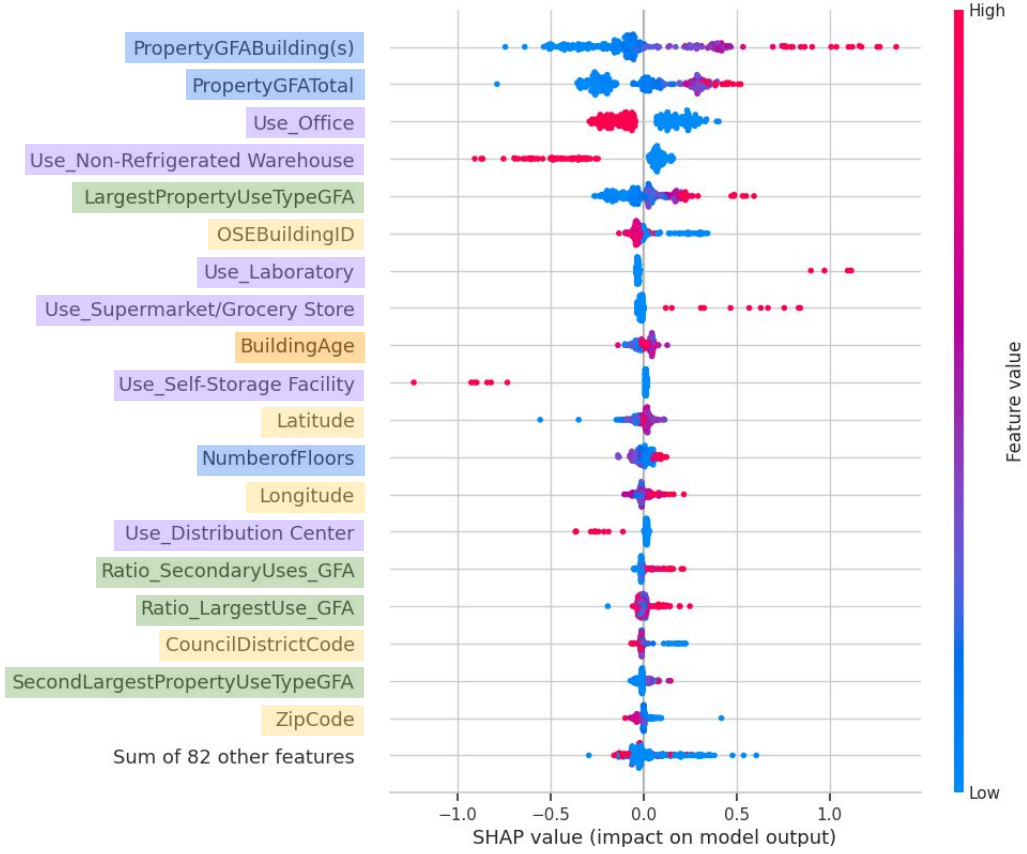

Observations

Facteurs dominants

- Surface totale du bâtiment
- Surfaces d'usage
- Usages spécifiques

Facteurs secondaires

- Âge du bâtiment
- Localisation

→ Les émissions de CO_2 sont principalement déterminés par la taille et l'usage des bâtiments

Influence de l'ENERGYSTARScore

Modèle	R^2 CV	MAE CV	RMSE CV
Sans EnergystarScore	0.58	0.71	0.91
Avec EnergyStarScore	↑0.63	↓0.68	↓0.85

Résultat

✔ Amélioration légère des performances
✔ Variable informative

Limite

⚠️ Score basé sur la performance énergétique
→ risque de **fuite d'information**

Conclusion

Utilisation pertinente uniquement si le score est disponible au moment de la prédiction

Synthèse du projet

Objectif

Prédire :

- la **consommation énergétique totale**
- les **émissions de CO_2**

des bâtiments non résidentiels.

Méthodologie

- Analyse exploratoire
- Comparaison de modèles ML
- Optimisation des hyperparamètres
- Interprétation avec SHAP

Résultats

Gradient Boosting retenu

$R^2 \approx$ **0.73** (énergie)
$R^2 \approx$ **0.52** (CO_2)

Facteurs dominants :

- surface totale
- usages du bâtiment

Limites et perspectives

Limites

- Variables d'exploitation absentes
- Forte dispersion des consommations et émissions
- Certains bâtiments atypiques

Perspectives

- Enrichir les données bâtiments
- Intégrer des données d'usage réel
- Tester des modèles de boosting avancés

Point clé final : Le machine learning permet d'identifier les principaux déterminants énergétiques des bâtiments et d'améliorer le suivi des émissions urbaines